



Desafio Inteligência de Dados PTC 26.1

Olá, aspirantes ao Citi 2026.2!

Para o desafio da área de Inteligência de Dados, preparamos uma imersão em alguma das etapas que vivenciamos aqui no Citi. O objetivo é que vocês se familiarizem com os desafios da nossa rotina e entendam como entregamos valor diariamente.

O desafio: Vocês receberão uma **base de dados real e despadronizada** com **transações financeiras**. Sua missão é **tratá-la**, garantir sua confiabilidade, e depois construir um **mini assistente com IA** capaz de responder perguntas sobre essas transações em linguagem natural. Estamos ansiosos para ver como vocês pensam!

O Cenário

Você é Analista de Dados recém-chegado(a) ao time financeiro do Citi. Seu gestor te passa uma base com mais de 1.000 transações dos últimos dois anos, mas ela está uma bagunça: CPFs em formatos diferentes, datas ambíguas, moedas estrangeiras misturadas com reais, status escritos de mil formas, duplicatas, linhas vazias e muito mais.

Antes de qualquer análise, **você precisa colocar a casa em ordem**. E depois, seu gestor quer algo a mais: **um assistente que responda perguntas sobre as transações sem precisar abrir a planilha toda vez**.

Etapa 1: Tratamento de Dados

Você receberá o arquivo  **Base de Dados PTC 26.1**. Sua primeira tarefa é **identificar e corrigir todas as inconsistências encontradas**.

A base possui as seguintes colunas:

Coluna	Descrição
Codigo_Transacao	Identificador único da transação
CPF_Cliente	CPF do cliente
Nome_Cliente	Nome do cliente
Data_Transacao	Data em que a transação ocorreu
Moeda	Moeda da transação
Valor_Transacao	Valor em reais da transação
Tipo_Transacao	Tipo: Transferência, Pagamento, Depósito, Saque ou PIX
Status_Transacao	Status: Aprovada, Recusada ou Pendente
Categoria	Categoria do gasto
Banco	Banco do cliente
Num_Parcelas	Número de parcelas da transação
Taxa_Servico	Taxa cobrada pelo serviço
Valor_Final	Valor final após taxas

O que tratar:

1. Nomes de colunas: Algumas colunas possuem espaços em branco no nome (ex: " Banco "). Remova esses espaços e garanta que todos os nomes de colunas estejam limpos.

2. Linhas completamente vazias: Existem linhas onde todos os campos estão nulos. Remova-as inteiramente.

3. Duplicatas: Existem linhas completamente duplicadas na base. Identifique e remova-as, mantendo apenas uma ocorrência.

4. CPF_Cliente: A coluna contém CPFs em 4 formatos diferentes: 123.456.789-00, 12345678900, 123.456.789.00 e 123-456-789-00. Padronize tudo para o formato 123.456.789-00. Preencha os nulos com Não informado.

5. Data_Transacao: A coluna contém datas em múltiplos formatos. Alguns são diretos (2024/01/15, 15.01.2024, 15-Jan-2024), mas outros são ambíguos: 01/02/2024 pode ser 1 de fevereiro (padrão brasileiro) ou 2 de janeiro (padrão americano). Padronize tudo para YYYY-MM-DD e justifique na documentação como você decidiu tratar as datas ambíguas.

6. Moeda e Valor_Transacao: A coluna Moeda deveria conter apenas BRL, mas existem transações em USD, EUR e GBP. Além disso, Valor_Transacao contém inconsistências de formato: símbolos de moeda (R\$), vírgulas como separador decimal e valores absurdos (0.0, -1200.0, 99999999.0). Converta todos os valores para BRL usando as taxas de conversão abaixo, remova os outliers e preencha os nulos com a mediana. Após o tratamento, atualize a coluna Moeda para BRL em todos os registros. Taxas de conversão (referência):

- 1 USD = R\$ 5,00
- 1 EUR = R\$ 5,50

- 1 GBP = R\$ 6,30

7. Tipo_Transacao: Existem variações como **transferencia**, **TED**, **DOC**, **Transf.**, **Boleto**, **pgto.**, **Resgate**, **PIX**, **P-I-X**, entre outros. Padronize para: **Transferência**, **Pagamento**, **Depósito**, **Saque** ou **PIX**. Atenção: algumas variações exigem interpretação, **TED** e **DOC** são tipos de transferência, **Boleto** é um pagamento, **Resgate** é um saque. Justifique seu mapeamento na documentação. Preencha os nulos com a moda da coluna.

8. Status_Transacao: Existem variações como **aprovada**, **APROVADA**, **Autorizada**, **Negada**, **Bloqueada**, **Em processamento**, **Aguardando**, entre outros. Padronize para: **Aprovada**, **Recusada** ou **Pendente**.

9. Nome_Cliente: Existem nomes em caixa alta, caixa baixa, com sublinhados, com apenas o primeiro nome ou com sobrenome duplicado. Padronize para o formato título (**Camila Rocha**), substitua sublinhados por espaço e remova espaços extras. Para nomes incompletos ou duplicados, trate como achar mais adequado e justifique.

10. Num_Parcels: A coluna contém valores misturados com texto: **1x**, **3 parcelas**, **única**, **6.0**, **2 vezes**. Converta tudo para inteiro.

11. Taxa_Servico: Existem valores negativos, o que é impossível para uma taxa de serviço. Corrija-os para o valor absoluto e preencha os nulos com a média da coluna.

12. Valor_Final inconsistente: O **Valor_Final** deve ser sempre maior ou igual ao **Valor_Transacao**. Existem registros onde isso é violado. Identifique e corrija recalculando: **Valor_Final = Valor_Transacao + Taxa_Servico**.

Ferramentas permitidas:

Python com Pandas: Pode rodar localmente no VS Code ou online pelo Google Colab, sem precisar instalar nada.

Google Sheets: Faça uma cópia da base e trate diretamente na planilha.



Etapa 2: Mini Assistente com IA (Opcional)

Quer ir além? Com os dados tratados em mãos, você vai construir um assistente simples que responde perguntas sobre as transações em linguagem natural, usando a API do Gemini diretamente, sem frameworks complexos.

Esta etapa não é obrigatória, mas é um diferencial importante. Demonstra querência, curiosidade e vontade de ir além. Se você fez a Etapa 1 no Google Sheets, ainda sim pode se arriscar e tentar aprender Python para chegar até aqui. Exercite o DNA experimentador e se jogue!

O problema do contexto:

A IA não consegue processar 1.000 linhas de dados brutas num único prompt, o texto seria grande demais. Por isso, **antes de fazer qualquer pergunta**, você precisa transformar os dados em um resumo analítico usando Pandas.

Não mande isso para a IA:

None

```
TXN000001, Ana Silva, 2024-01-15, 1500.00, PIX, Aprovada...
```

```
TXN000002, Bruno Oliveira, 2024-01-16, 320.00, Pagamento, Recusada...
```

```
(... 1000 linhas)
```

Mande isso:

None

```
Resumo da base de transações financeiras (Jan/2023 a Dez/2024):
```

- Total de transações: 1.000
- Valor total movimentado: R\$ 7.823.450,00

- Por status: Aprovadas 612 (61,2%), Recusadas 198 (19,8%), Pendentes 190 (19%)
- Por tipo: PIX 245, Transferência 210, Pagamento 198, Depósito 187, Saque 160
- Por banco – total e taxa de recusa: Nubank 230 (18%), Bradesco 198 (22%)...
- Por categoria: Alimentação 198, Saúde 175, Transporte 162...
- Clientes com mais transações recusadas: Bruno Oliveira (12), Ana Silva (9)...
- Ticket médio por tipo: PIX R\$ 850, Transferência R\$ 2.300...

Esse resumo é calculado por você com Pandas e montado como uma string antes de chamar a API. A qualidade das respostas da IA depende diretamente de quão bem você estruturou esse contexto. **Esse é o coração do desafio.**

O que o script do assistente deve fazer:

1. Carregar o CSV tratado
2. Calcular os agregados e montar o resumo como texto
3. Receber uma pergunta do usuário via `input()`
4. Chamar a API do Gemini com o resumo + a pergunta
5. Exibir a resposta no terminal

Perguntas obrigatórias:

Seu assistente será testado com as 5 perguntas abaixo. Não existe uma resposta única certa, o que será avaliado é a **qualidade da sua análise e do contexto que**

você montou. Um bom contexto fornece informações suficientes para a IA raciocinar sobre os dados, não apenas responder no escuro.

1. *"Existe algum padrão suspeito nas transações recusadas? O que chama atenção?"*
2. *"Quais clientes têm o comportamento financeiro mais fora do comum com base nos dados? Por quê?"*
3. *"Analisando o período completo, quais tendências você identificaria para apresentar em uma reunião executiva?"*
4. *"Tem algum banco que se destaca negativamente? O que os dados sugerem sobre ele?"*
5. *"Se você fosse recomendar uma ação para o time financeiro com base nesses dados, qual seria e por quê?"*

Dica: A API do Gemini possui um tier gratuito acessível com conta Google em aistudio.google.com. Não é necessário cartão de crédito. Como alternativa, o **Groq** também oferece acesso gratuito sem cartão em console.groq.com.

Entregáveis e Critérios de Avaliação

Você tem até o dia **02/05/2026** para nos entregar:

- 1. Dados tratados (obrigatório):** O arquivo final padronizado e enriquecido em **.csv** ou **.xlsx**.
- 2. Código (obrigatório):** O arquivo **.py**, **.ipynb** ou link do Google Colab com o tratamento de dados. Se fez a Etapa 2, inclua também o script do assistente.
- 3. Documentação (obrigatório):** Um resumo explicando as decisões que você tomou: como identificou e tratou cada inconsistência, e o que cada etapa do seu código faz (Ou se fez diretamente no sheets, explicar cada passo).
- 4. Respostas do assistente (obrigatório apenas se fez a Etapa 2):** Um print ou documento mostrando as 5 perguntas e as respostas geradas pelo seu assistente, com uma breve explicação sua de se fazem sentido ou não.

5. Uso de Inteligência Artificial A IA é uma ferramenta poderosa e encorajamos o uso para otimizar tempo. No entanto, exigimos total transparência. Deixe uma seção final detalhando se e como você usou IA (ex: *"Usei o ChatGPT para me ajudar a escrever a função de padronização de datas"*). A IA deve ser sua assistente, não a autora principal do seu raciocínio.

Conteúdos de apoio:

[pandas documentation – pandas 3.0.2 documentation](#)

[Guia de início rápido da API Gemini | Gemini API | Google AI for Developers](#)

<https://aistudio.google.com/>